

**SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN**

**Behrić Lorena
Selimi Anid**

**ISPITIVANJE UTJECAJA RAZLIČITIH
ARHITEKTURA NEURONSKIH MREŽA NA
KVALITETU MODELA KLASTIFIKACIJE U
DUBINKSOM UČENJU**

PROJEKT

UVOD U UMJETNU INTELIGENCIJU

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Behrić Lorena
Selimi Anid

Matični broj: 0016148153
0016155165

Studij: Informacijski i poslovni sustavi

ISPITIVANJE UTJECAJA RAZLIČITIH ARHITEKTURA NEURONSKIH
MREŽA NA KVALITETU MODELA KLASTIFIKACIJE U DUBINKSOM
UČENJU

PROJEKT

Mentor:

doc. dr. sc. Bogdan Okreša Đurić

Varaždin, siječanj 2026.

*Behrić Lorena
Selimi Anid*

Izjava o izvornosti

Izjavljujem da je ovaj projekt izvorni rezultat mog rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autorica potvrdila prihvatanjem odredbi u sustavu FOI Radovi

Sažetak

Ovaj projektni zadatak bavi se analizom i usporedbom različitih arhitektura konvolucijskih neuronskih mreža (konvolucijska neuronska mreža (CNN)) u kontekstu zadatka klasifikacije slika. U radu se teorijski obrađuju osnove neuronskih mreža i dubinskog učenja, dok se praktični dio obuhvaća implementaciju i evaluaciju triju CNN varijanti u programskom jeziku Python u okruženju Google Colaboratory. Eksperimentalna analiza provedena je na skupu podataka Fashion-MNIST, koji sadrži slike odjevnih predmeta raspoređene u deset klasa. Usporedba modela temelji se na rezultatima evaluacije na testnom skupu te na analizi krivulja učenja tijekom epoha treniranja. Rezultati pokazuju da promjene u dubini mreže i primjena metoda smanjenja prenaučenosti utječu na kvalitetu klasifikacije i stabilnost procesa učenja. Rad doprinosi razumijevanju utjecaja arhitekture CNN modela na uspješnost klasifikacije te pruža osnovu za daljnja eksperimentalna ispitivanja i optimizaciju modela.

Ključne riječi: dubinsko učenje; konvolucijska neuronska mreža; klasifikacija slika; Fashion-MNIST; arhitektura modela; dropout; batch normalization

Sadržaj

1. Uvod	1
2. Metode i tehnike rada	2
3. Razrada teme	3
3.1. Neuronske mreže i dubinsko učenje	3
3.2. Arhitekture neuronskih mreža za klasifikaciju	3
3.3. Skup podataka i predobrada	4
4. Opis implementacije	5
4.1. Definicija arhitekture CNN modela	5
4.1.1. Osnovni CNN model	5
4.1.2. Dublji CNN model	6
4.1.3. CNN model s Dropout i Batch Normalization slojevima	6
5. Analiza rezultata	9
6. Zaključak	12
Popis literature	13
Popis slika	14
Popis isječaka koda	15

1. Uvod

Cilj projektnog zadatka je primijeniti teorijsko znanja stečeno na kolegiju Uvod u umjetnu inteligenciju kroz razvoj, implementaciju i analizu modela koji rješava konkretan problem primjenom metoda umjetne inteligencije. Tema projekta nosi naziv Ispitivanje utjecaja različitih arhitektura neuronskih mreža na kvalitetu modela klasifikacije u dubinskom učenju. Riječ je o istraživačkom pristupu u kojem se promatra kako struktura i tip neuronske mreže utječu na performanse modela u zadatku klasifikacije. Motivacija za odabir ove teme proizlazi iz činjenice da su neuronske mreže postale temeljna tehnologija suvremene umjetne inteligencije. Njihova se primjena proteže na područja kao što su računalni vid, obrada prirodnog jezika, medicinska dijagnostika i analiza podataka velikog opsega. Budući da kvaliteta modela uvelike ovisi o njegovoj arhitekturi, cilj ovog projekta je eksperimentalno utvrditi koje arhitekture ostvaruju bolje rezultate u zadatku klasifikacije koristeći pristup dubinskog učenja. Projekt uključuje teorijski i praktični dio. U teorijskom dijelu prikazuju se osnovni koncepti neuronskih mreža i načela dubinskog učenja s naglaskom na konvolucijske neuronske mreže u klasifikaciji slika. U praktičnom dijelu implementiraju se i uspoređuju tri varijante CNN modela u programskom jeziku Python, u razvojnom okruženju Google Colaboratory. Testiranja se provode nad skupom podataka Fashion-MNIST te se analiziraju postignuti rezultati pomoću standardnih metrika evaluacije. [1].

2. Metode i tehnike rada

Istraživanje je provedeno metodom eksperimentalne usporedbe modela dubinskog učenja, pri čemu se pod jednakim uvjetima treniranja i evaluacije uspoređuju tri različite arhitekture konvolucijskih neuronskih mreža (CNN). Takav pristup omogućuje promatranje utjecaja arhitekture na kvalitetu klasifikacije uz kontrolu ostalih čimbenika eksperimenta. Implementacija je izvedena u programskom jeziku Python u okruženju Google Colaboratory, koristeći biblioteke TensorFlow i Keras za definiranje modela, konfiguraciju postupka učenja te treniranje i evaluaciju neuronskih mreža (Ćosić, 2020). U praktičnom dijelu uspoređuju se tri CNN varijante koje se razlikuju po dubini i primjeni slojeva za smanjenje prenaučivosti i stabilizaciju učenja. Prva arhitektura predstavlja osnovni CNN model s konvolucijskim slojevima i slojevima sažimanja Max Pooling, nakon čega slijedi potpuno povezani sloj i izlazni sloj s funkcijom softmax. Druga arhitektura proširuje osnovni model dodavanjem dodatnih konvolucijskih slojeva čime se povećava kapacitet mreže za učenje složenijih značajki. Treća arhitektura temelji se na dubljem modelu, ali uključuje Dropout i Batch Normalization slojeve s ciljem smanjenja prenaučivosti i stabilnijeg treniranja. Eksperimenti su provedeni na skupu podataka Fashion-MNIST, uz standardnu predobradu koja uključuje normalizaciju vrijednosti piksela i prilagodbu oblika ulaza konvolucijskim slojevima. Za sve modele korišten je optimizacijski algoritam Adam te funkcija gubitka categorical cross-entropy koja je prikladna za višeklasnu klasifikaciju uz primjenu ranog zaustavljanja (Early Stopping) tijekom treniranja. Kvaliteta modela procjenjuje se na testnom skupu pomoću točnosti i vrijednosti funkcije gubitka, dok se tijekom učenja dodatno analizira putem krivulja učenja. Budući da su svi modeli trenirani nad istim podacima i pod usporedivim hiperparametrima (npr. broj epoha i veličina serije), uočene razlike u rezultatima mogu se primarno pripisati razlikama u arhitekturi mreže.

3. Razrada teme

U ovom poglavlju prikazuje se teorijska podloga i kontekst praktičnog dijela projektnog zadatka. Najprije se objašnjavaju osnovni pojmovi neuronskih mreža i dubinskog učenja s naglaskom na konvolucijske neuronske mreže koje su prikladne za obradu slikovnih podataka. Zatim se opisuje uloga arhitekture CNN-a te se daje metodološki okvir za eksperimentalnu usporedbu triju CNN varijanti. Na kraju se sažeto prikazuje odabrani skup podataka Fashion-MNIST i predobrada potrebna za treniranje modela čime se uspostavlja jasna poveznica između teorijskog dijela i implementacije.

3.1. Neuronske mreže i dubinsko učenje

Neuronske mreže pripadaju skupini metoda strojnog učenja koje se temelje na ideji učenja preslikavanja između ulaznih značajki i izlaznih oznaka (klasa) na temelju primjera. U kontekstu kolegija Uvod u umjetnu inteligenciju, neuronske mreže promatraju se kao dio statističkog pristupa umjetnoj inteligenciji, a dubinsko učenje opisuje se kao rad s vrlo velikim neuronskim mrežama koje imaju veći broj skrivenih slojeva, čime se omogućuje učenje složenijih reprezentacija podataka (Schatten, 2023.). Osnovna struktura neuronske mreže sastoji se od ulaznog sloja, jednog ili više skrivenih slojeva i izlaznog sloja. Učenje se provodi prilagodbom parametara (težina i pomaka) kako bi se minimizirala pogreška predviđanja na skupu za učenje. U praksi se u klasifikacijskim problemima često koriste aktivacijske funkcije koje omogućuju nelinearnost modela te optimizacijski postupci temeljeni na gradijentnom spustu uz funkcije gubitka prilagođene vrsti klasifikacije (binarna ili višerazredna). Ovakav okvir omogućuje usporedbu arhitektura pod jednakim uvjetima treniranja što je temeljna pretpostavka za objektivnu eksperimentalnu analizu.

3.2. Arhitekture neuronskih mreža za klasifikaciju

U području klasifikacije podataka koriste se različite arhitekture neuronskih mreža. Oda-bir arhitekture ovisi o strukturi ulaznih podataka i prirodi problema. U teorijskom smislu često se razlikuju duboke potpuno povezane mreže (DNN), konvolucijske neuronske mreže (CNN) te povratne neuronske mreže (RNN) jer svaka od njih uvodi drugačije pretpostavke o načinu na koji se informacija obrađuje i koje se značajke mogu učinkovito naučiti (Ćosić, 2020). U ovom projektnom zadatku naglasak je stavljen na konvolucijske neuronske mreže budući da se praktični dio odnosi na klasifikaciju slikovnih podataka pri čemu CNN predstavlja standardan i metodološki najprikladniji izbor (Kokanović, 2025). DNN arhitekture sastoje se od više gusto povezanih slojeva u kojima je svaki neuron povezan sa svim neuronima prethodnog sloja. Takav pristup može biti učinkovit kada se ulaz može prikazati kao vektor značajki. Kod podataka s izraženom prostornom strukturom, poput slika, potpuno povezani slojevi ne iskorištavaju lokalne odnose između susjednih piksela te često zahtijevaju veći broj parametara zbog čega mogu biti osjetljiviji na prenaučenosť (Ćosić, 2020). Konvolucijske neuronske mreže uvode konvolu-

cijske slojeve koji uče filtre nad lokalnim područjima ulaza te se često kombiniraju sa slojevima sažimanja (pooling). Time se omogućuje učenje prostornih uzoraka i hijerarhijskih značajki, a dijeljenje parametara konvolucijskih filtara smanjuje ukupnu složenost modela i doprinosi boljoj generalizaciji u odnosu na potpuno povezane pristupe (Kokanović, 2025). U skladu s time, u praktičnom dijelu ovog projekta uspoređuju se različite arhitekture CNN-a pri čemu se promatra utjecaj dubine mreže i primjene slojeva za smanjenje prenaučivosti i stabilizaciju učenja. Usporedba obuhvaća osnovni CNN model, dublji CNN model te dublji CNN model koji uključuje Dropout i Batch Normalization slojeve kojima se ispituje kako promjene u arhitekturi utječu na točnost klasifikacije i stabilnost procesa treniranja. RNN arhitekture koriste povratne veze kako bi modelirale ovisnosti u sekvencama i najčešće se primjenjuju na vremenske nizove ili tekstualne podatke gdje redoslijed elemenata nosi informaciju (Čosić, 2020). Iako su važne u širem kontekstu dubinskog učenja, u ovom projektu nisu dio usporedbe jer se promatrani problem odnosi na slikovne podatke te je fokus stavljen na varijante konvolucijskih modela.

3.3. Skup podataka i predobrada

Kako bi usporedba arhitektura bila jasna u praktičnom dijelu odabran je standardizirani problemski zadatak klasifikacije slika koji je čest u uvodu u dubinsko učenje. U ovom radu korišten je skup podataka Fashion-MNIST koji zadržava sličnu strukturu kao MNIST, ali predstavlja realističniji i zahtjevniji problem jer obuhvaća deset klasa odjevnih predmeta. Fashion-MNIST sadrži 60 000 slika za učenje i 10 000 slika za testiranje. Odabirom takvog skupa podataka osigurava se da je problem dovoljno složen za usporedbu različitih CNN arhitektura, ali i računalno izvediv u okruženju Google Colaboratory. Predobrada podataka provodi se kako bi ulaz bio prikladan za učenje neuronskih mreža i kako bi se osigurala numerička stabilnost tijekom treniranja. Vrijednosti piksela normaliziraju se na interval $[0, 1]$ dijeljenjem s 255, a ulazni podaci preoblikuju se tako da odgovaraju ulaznom obliku konvolucijskih slojeva ($28 \times 28 \times 1$). Oznake klasa pripremaju se za višerazrednu klasifikaciju pri čemu se prema potrebi provodi i jedno-kратно kodiranje (one-hot) kako bi izlaz bio usklađen s izlaznim slojem (softmax) i odabranom funkcijom gubitka. Kako bi usporedba modela bila metodološki utemeljena koristi unaprijed definiranu podjelu skupa na podatke za učenje i testiranje uz izdvajanje validacijskog skupa iz skupa za učenje tijekom treniranja. Time se omogućuje praćenje generalizacije modela i primjena tehnika poput ranog zaustavljanja (Early Stopping) u slučaju izostanka poboljšanja na validacijskim podacima.

4. Opis implementacije

Aplikacija je implementirana u obliku interaktivne Jupyter bilježnice u Google Colab okruženju, koristeći programski jezik Python i biblioteku TensorFlow/Keras. Sustav je namijenjen ispitivanju utjecaja različitih arhitektura konvolucijskih neuronskih mreža (CNN) na kvalitetu klasifikacije slika u kontekstu dubokog učenja. Google Colab okruženje omogućuje jednostavno izvođenje aplikacije bez potrebe za lokalnom instalacijom alata, kao i korištenje dostupnih računalnih resursa za treniranje neuronskih mreža. Kao skup podataka korišten je Fashion-MNIST, koji sadrži 60 000 slika za učenje i 10 000 slika za testiranje, dimenzija 28×28 piksela u sivim tonovima, raspoređenih u deset klasa odjevnih predmeta. Fashion-MNIST odabran je kao standardizirani i često korišten skup podataka u području dubokog učenja jer predstavlja realističniji i zahtjevniji problem od klasičnog MNIST skupa s rukom pisanim znamenkama, dok istovremeno zadržava jednostavnost potrebnu za učinkovito eksperimentalno ispitivanje i usporedbu modela. Time se osigurava ravnoteža između složenosti problema i računalne izvedivosti. Podaci su prethodno normalizirani dijeljenjem vrijednosti piksela s 255 kako bi se osigurala numerička stabilnost tijekom učenja, a oznake klasa pretvorene su u jednokratno kodirani (one-hot) oblik. Ulazni podaci dodatno su preoblikovani kako bi odgovarali ulaznom obliku konvolucijskih slojeva neuronske mreže. Implementacija sustava sastoji se od tri različite arhitekture konvolucijskih neuronskih mreža, koje se detaljnije opisuju u nastavku poglavlja.

4.1. Definicija arhitekture CNN modela

U praktičnom dijelu projektnog zadatka implementirane su tri različite arhitekture konvolucijskih neuronskih mreža (CNN) kako bi se ispitao utjecaj strukture mreže na kvalitetu klasifikacije. U nastavku su prikazani pojednostavljeni isječci koda koji ilustriraju razlike između promatranih modela. Kod je prikazan u skraćenom obliku radi preglednosti, dok su detalji implementacije dostupni u Jupyter bilježnici.

4.1.1. Osnovni CNN model

Osnovni model sastoji se od dva konvolucijska sloja s pripadajućim slojevima sažimanja (Max Pooling), nakon čega slijede potpuno povezani sloj i izlazni sloj s funkcijom softmax.

```
1 model = Sequential([
2     Conv2D(32, (3,3), activation='relu', input_shape=(28,28,1)),
3     MaxPooling2D((2,2)),
4     Conv2D(64, (3,3), activation='relu'),
5     MaxPooling2D((2,2)),
6     Flatten(),
7     Dense(128, activation='relu'),
8     Dense(10, activation='softmax')
9 ])
```

Isječak koda 1: Osnovna arhitektura CNN modela

4.1.2. Dublji CNN model

Dublji CNN model proširuje osnovnu arhitekturu dodavanjem dodatnih konvolucijskih slojeva, čime se povećava kapacitet mreže za učenje složenijih značajki iz ulaznih slika.

```
1 model = Sequential([
2     Conv2D(32, (3,3), activation='relu', input_shape=(28,28,1)),
3     Conv2D(32, (3,3), activation='relu'),
4     MaxPooling2D((2,2)),
5     Conv2D(64, (3,3), activation='relu'),
6     Conv2D(64, (3,3), activation='relu'),
7     MaxPooling2D((2,2)),
8     Flatten(),
9     Dense(128, activation='relu'),
10    Dense(10, activation='softmax')
11 ])
```

Isječak koda 2: Dublja arhitektura CNN modela

4.1.3. CNN model s Dropout i Batch Normalization slojevima

Treća arhitektura temelji se na dubljem CNN modelu, ali dodatno uključuje Dropout i Batch Normalization slojeve s ciljem smanjenja prenaučivosti i stabilizacije procesa učenja.

```
1 model = Sequential([
2     Conv2D(32, (3,3), activation='relu', input_shape=(28,28,1)),
3     BatchNormalization(),
4     Conv2D(32, (3,3), activation='relu'),
5     MaxPooling2D((2,2)),
6     Dropout(0.25),
7     Conv2D(64, (3,3), activation='relu'),
8     BatchNormalization(),
9     Conv2D(64, (3,3), activation='relu'),
10    MaxPooling2D((2,2)),
11    Dropout(0.25),
12    Flatten(),
13    Dense(128, activation='relu'),
14    Dropout(0.5),
15    Dense(10, activation='softmax')
16 ])
```

Isječak koda 3: CNN arhitektura s Dropout i Batch Normalization slojevima

Prikazani isječci koda jasno ilustriraju razlike u dubini mreže i primjeni regularizacijskih tehnika, što omogućuje povezivanje arhitekture modela s rezultatima dobivenima u eksperimentalnoj analizi.

Očekuje se da povećana dubina mreže može dovesti do poboljšanja točnosti klasifikacije, uz povećani rizik od prenaučivosti. Model s Dropout i Batch Normalization slojevima temelji se na dubljij arhitekturi, ali dodatno uključuje regularizacijske tehnike s ciljem smanjenja prenaučivosti i stabilizacije procesa učenja. Dropout slojevi nasumično isključuju dio neurona tijekom treniranja, dok Batch Normalization doprinosi stabilnijoj i bržoj konvergenciji modela. Za treniranje svih modela korišten je Adam optimizacijski algoritam te funkcija gubitka categorical cross-entropy, prikladna za višeklasnu klasifikaciju. Tijekom treniranja primijenjena je tehnika

ranog zaustavljanja (Early Stopping), koja automatski prekida proces učenja u slučaju izostanka poboljšanja na validacijskom skupu podataka. Time se smanjuje rizik od prenaučivosti i optimizira vrijeme treniranja modela. Tijek treniranja pojedinih modela praćen je ispisima po epohama, koji uključuju vrijednosti točnosti i gubitka na skupu za učenje i validaciju. Primjeri tih ispisa prikazani su na slikama treniranja, čime je dodatno ilustriran proces učenja modela i djelovanje tehnike ranog zaustavljanja.

```
=====
Treniram model: Osnovni
=====
Epoch 1/10
1875/1875 ----- 38s 20ms/step - accuracy: 0.7831 - loss: 0.6006 - val_accuracy: 0.8715 - val_loss: 0.3601
Epoch 2/10
1875/1875 ----- 38s 20ms/step - accuracy: 0.8889 - loss: 0.3074 - val_accuracy: 0.8898 - val_loss: 0.3056
Epoch 3/10
1875/1875 ----- 40s 20ms/step - accuracy: 0.9051 - loss: 0.2603 - val_accuracy: 0.9043 - val_loss: 0.2611
Epoch 4/10
1875/1875 ----- 37s 20ms/step - accuracy: 0.9172 - loss: 0.2232 - val_accuracy: 0.9033 - val_loss: 0.2611
Epoch 5/10
1875/1875 ----- 37s 20ms/step - accuracy: 0.9284 - loss: 0.1940 - val_accuracy: 0.9126 - val_loss: 0.2450
Epoch 6/10
1875/1875 ----- 37s 20ms/step - accuracy: 0.9387 - loss: 0.1652 - val_accuracy: 0.9093 - val_loss: 0.2517
Epoch 7/10
1875/1875 ----- 40s 19ms/step - accuracy: 0.9437 - loss: 0.1466 - val_accuracy: 0.9014 - val_loss: 0.2864
Epoch 8/10
1875/1875 ----- 36s 19ms/step - accuracy: 0.9521 - loss: 0.1272 - val_accuracy: 0.9115 - val_loss: 0.2697
Epoch 8: early stopping
```

Slika 1: Ispis tijekom treniranja osnovnog CNN modela uz primjenu tehnike ranog zaustavljanja.

```
=====
Treniram model: Dublji
=====
Epoch 1/10
1875/1875 ----- 90s 47ms/step - accuracy: 0.7704 - loss: 0.6249 - val_accuracy: 0.8846 - val_loss: 0.3265
Epoch 2/10
1875/1875 ----- 87s 46ms/step - accuracy: 0.8959 - loss: 0.2815 - val_accuracy: 0.9055 - val_loss: 0.2616
Epoch 3/10
1875/1875 ----- 162s 57ms/step - accuracy: 0.9133 - loss: 0.2347 - val_accuracy: 0.9056 - val_loss: 0.2550
Epoch 4/10
1875/1875 ----- 85s 46ms/step - accuracy: 0.9285 - loss: 0.1926 - val_accuracy: 0.9166 - val_loss: 0.2358
Epoch 5/10
1875/1875 ----- 85s 45ms/step - accuracy: 0.9359 - loss: 0.1720 - val_accuracy: 0.9154 - val_loss: 0.2357
Epoch 6/10
1875/1875 ----- 87s 46ms/step - accuracy: 0.9433 - loss: 0.1518 - val_accuracy: 0.9174 - val_loss: 0.2381
Epoch 7/10
1875/1875 ----- 87s 46ms/step - accuracy: 0.9515 - loss: 0.1299 - val_accuracy: 0.9179 - val_loss: 0.2431
Epoch 8/10
1875/1875 ----- 83s 44ms/step - accuracy: 0.9595 - loss: 0.1101 - val_accuracy: 0.9178 - val_loss: 0.2448
Epoch 8: early stopping
```

Slika 2: Ispis tijekom treniranja dubljeg CNN modela uz primjenu tehnike ranog zaustavljanja.

```

=====
Treniram model: Dropout+BN
=====
Epoch 1/10
1875/1875 ————— 102s 54ms/step - accuracy: 0.6960 - loss: 0.8719 - val_accuracy: 0.8557 - val_loss: 0.3904
Epoch 2/10
1875/1875 ————— 98s 52ms/step - accuracy: 0.8428 - loss: 0.4434 - val_accuracy: 0.8784 - val_loss: 0.3286
Epoch 3/10
1875/1875 ————— 98s 52ms/step - accuracy: 0.8678 - loss: 0.3726 - val_accuracy: 0.8911 - val_loss: 0.2947
Epoch 4/10
1875/1875 ————— 105s 56ms/step - accuracy: 0.8832 - loss: 0.3256 - val_accuracy: 0.9012 - val_loss: 0.2777
Epoch 5/10
1875/1875 ————— 108s 58ms/step - accuracy: 0.8899 - loss: 0.3092 - val_accuracy: 0.9103 - val_loss: 0.2463
Epoch 6/10
1875/1875 ————— 108s 58ms/step - accuracy: 0.8968 - loss: 0.2874 - val_accuracy: 0.9105 - val_loss: 0.2498
Epoch 7/10
1875/1875 ————— 108s 58ms/step - accuracy: 0.9007 - loss: 0.2759 - val_accuracy: 0.9108 - val_loss: 0.2525
Epoch 8/10
1875/1875 ————— 108s 58ms/step - accuracy: 0.9045 - loss: 0.2660 - val_accuracy: 0.9089 - val_loss: 0.2531
Epoch 8: early stopping

```

Slika 3: Ispis tijeka treniranja CNN modela s Dropout i Batch Normalization slojevima uz primjenu ranog zaustavljanja.


5. Analiza rezultata

U okviru projekta provedeno je eksperimentalno ispitivanje utjecaja različitih arhitektura konvolucijskih neuronskih mreža na kvalitetu klasifikacije slika. Za usporedbu su korištene tri arhitekture: osnovni CNN model, dublji CNN model te CNN model s dodatnim Dropout i Batch Normalization slojevima. Svi modeli trenirani su i evaluirani na istom skupu podataka (Fashion-MNIST) i pod jednakim uvjetima, čime je osigurana objektivna usporedba rezultata. Konačni rezultati evaluacije prikazani su u Tablici 1, u kojoj su navedene vrijednosti točnosti i funkcije gubitka na testnom skupu podataka. Iz prikazanih rezultata vidljivo je da je dublji model postigao


	Model	Test accuracy	Test loss
1	Dublji	0.9178	0.244829
0	Osnovni	0.9115	0.269659
2	Dropout+BN	0.9089	0.253149

Slika 4: Rezultati evaluacije CNN modela na testnom skupu Fashion-MNIST.

najveću točnost klasifikacije od 91.78%, čime se pokazao najuspješnijim među promatranim arhitekturama. Osnovni model ostvario je nešto nižu točnost od 91.15 %, dok je model s Dropout i Batch Normalization slojevima postigao točnost od 90.89%. Iako je model s regularizacijskim tehnikama ostvario najnižu maksimalnu točnost, njegovi rezultati i dalje su vrlo konkurentni. Za detaljniju analizu procesa učenja promatrane su krivulje validacijske točnosti tijekom epoha treniranja, prikazane na Slici 1. Analiza krivulja pokazuje da dublji model najbrže konvergira i postiže najvišu vrijednost validacijske točnosti. Osnovni model pokazuje veće oscilacije tijekom treniranja, dok model s Dropout i Batch Normalization slojevima ima najstabilniji tijek učenja. Dodatna analiza provedena je promatranjem vrijednosti validacijskog gubitka tijekom epoha, prikazana na Slici 2. Model s Dropout i Batch Normalization slojevima pokazuje najstabilniji pad vrijednosti gubitka, što upućuje na smanjeni rizik od prenaučivosti, dok dublji model predstavlja dobar kompromis između niske vrijednosti gubitka i visoke točnosti klasifikacije. Na temelju dobivenih rezultata može se zaključiti da arhitektura neuronske mreže značajno utječe na kvalitetu klasifikacije slika. Povećanje dubine mreže može dovesti do veće točnosti, dok primjena regularizacijskih tehnika doprinosi stabilnijem učenju i boljoj generalizaciji.



Slika 5: Usporedba validacijske točnosti (val_accuracy) tijekom epoha treniranja za osnovni, dublji i CNN model s Dropout i Batch Normalization slojevima.



Slika 6: Usporedba validacijskog gubitka (val_loss) tijekom epoha treniranja za promatrane CNN arhitekture.

6. Zaključak

U ovom projektnom zadatku provedeno je eksperimentalno ispitivanje utjecaja različitih arhitektura konvolucijskih neuronskih mreža (CNN) na kvalitetu klasifikacije slika. Teorijski dio rada prikazao je opće principe dubinskog učenja i neuronskih mreža dok je praktični dio bio usmjeren na usporedbu triju CNN arhitektura: osnovnog modela, dubljeg modela te modela koji uz dublju arhitekturu uključuje Dropout i Batch Normalization kao regularizacijske tehnike. Eksperimentalni rezultati pokazali su da promjene u arhitekturi mogu utjecati na uspješnost klasifikacije. Dublji model ostvario je najbolju točnost što upućuje na prednost većeg kapaciteta mreže u učenju složenijih značajki. Model s Dropout i Batch Normalization slojevima pokazao je stabilniji tijek učenja i manju osjetljivost na prenaučенost čime se potvrđuje korisnost regularizacijskih tehnika u poboljšanju generalizacije. Osnovni model postiže nešto niže rezultate u odnosu na dublje arhitekture, ali predstavlja dobru referentnu točku i jednostavniju varijantu koja je računalno učinkovitija. Zaključno, može se istaknuti da je pri dizajnu modela za klasifikaciju slika potrebno uskladiti arhitekturu s prirodom podataka i ciljevima sustava, pri čemu povećanje dubine može donijeti dobitak u točnosti, a primjena regularizacije pridonijeti stabilnosti i otpornosti modela. Dobiveni rezultati potvrđuju važnost eksperimentalnog pristupa pri odabiru arhitekture neuronske mreže u zadacima dubinskog učenja.

Popis literature

- [1] D. Oraić Tolić, *Akademsko pismo: Strategije i tehnike klasične retorike za suvremene studentice i studente*. Zagreb: Naklada Ljevak, 2011.
- [2] A. Ćosić, „Primjena neuronskih mreža za otkrivanje napada,” Diplomski rad, Sveučilište u Zagrebu, Fakultet organizacije i informatike, Varaždin, 2020.
- [3] K. Kokanović, „Upotreba dubokog učenja za klasifikaciju tehničkih dokumenata,” Diplomski rad, Sveučilište Josipa Jurja Strossmayera u Osijeku, Fakultet elektrotehnike, računarstva i informacijskih tehnologija (FERIT), Osijek, 2025.
- [4] A. Đurišić, „Implementacija i evaluacija tehnika klasifikacije teksta zasnovanih na Bajesovoj teoremi,” Završni rad / rad (vrsta prema izvorniku), Univerzitet u Beogradu, Beograd, 2014.
- [5] M. Schatten, *Uvod u umjetnu inteligenciju – skripte s predavanja*, Nastavni materijali, Fakultet organizacije i informatike, 2023.
- [6] M. Schatten, *Uvod u umjetnu inteligenciju – prezentacije s predavanja*, Nastavni materijali, Fakultet organizacije i informatike, 2023.
- [7] OpenAI. „Chatgpt.” Web aplikacija, pogledano 16. siječnja 2026. adresa: <https://chat.openai.com/>.
- [8] OpenAI. „Chatgpt – poveznica na razgovor.” Web aplikacija, pogledano 6. siječnja 2026. adresa: <https://chatgpt.com/share/69732ee0-5928-8000-b9b6-3761c4ebc43e>.

Popis slika

1.	Ispis tijeka treniranja osnovnog CNN modela uz primjenu tehnike ranog zaustavljanja.	7
2.	Ispis tijeka treniranja dubljeg CNN modela uz primjenu tehnike ranog zaustavljanja.	7
3.	Ispis tijeka treniranja CNN modela s Dropout i Batch Normalization slojevima uz primjenu ranog zaustavljanja.	8
4.	Rezultati evaluacije CNN modela na testnom skupu Fashion-MNIST.	9
5.	Usporedba validacijske točnosti (val_accuracy) tijekom epoha treniranja za osnovni, dublji i CNN model s Dropout i Batch Normalization slojevima.	10
6.	Usporedba validacijskog gubitka (val_loss) tijekom epoha treniranja za promatrane CNN arhitekture.	11

Popis isječka koda

1.	Osnovna arhitektura CNN modela	5
2.	Dublja arhitektura CNN modela	6
3.	CNN arhitektura s Dropout i Batch Normalization slojevima	6